Modelado en Optimización

Departamento de Ingeniería Industrial
Universidad de los Andes

Overview

Este curso ofrece una introducción al ***modelamiento, solución y análisis de problemas de optimización*** como herramienta de apoyo para la **toma de decisiones en diferentes dominios de aplicación**.

Al finalizar el curso, estarás en capacidad de:

- Identificar **situaciones susceptibles de ser mejoradas** a través de la optimización
- Representar **problemas de decisión** mediante modelos de programación lineal
- Implementar y analizar las **soluciones computacionales** correspondientes
- **Comunicar hallazgos y recomendaciones** a una audiencia amplia.

Modelar

Resolver

Analizar

Contenido

A lo largo de cuatro módulos, trabajarás para desarrollar las siguientes competencias:

- Representar **problemas de decisión** como **modelos matemáticos** de *programación lineal* y resolverlos computacionalmente mediante el complemento *Solver* en hojas de cálculo, comprendiendo las nociones de región factible, gradiente y optimalidad.

- Modelar problemas comunes de optimización lineal con variables continuas y enteras, e implementar **rutinas de solución y presentación de resultados** de optimización en Python.

- Diferenciar los **tipos de problemas** y principales **estrategias de solución** que se usan en aplicaciones prácticas de optimización, en **problemas de decisión** (analítica prescriptiva, investigación de operaciones) como en **problemas de estimación** (analítica predictiva, inteligencia artificial).

- Formular y resolver problemas de **decisiones secuenciales** bajo el paradigma de *programación dinámica*, y evaluar el desempeño de estrategias de solución exactas y aproximadas.

Módulo 1 — Optimización lineal con restricciones

Propósito: Desarrollar competencias de formulación y solución de modelos matemáticos de programación lineal (LP) en contextos de industria. → Muchos problemas industriales se aproximan “linealizando” el mundo

Contenido:

1. Geometría de un LP: región factible, gradiente, isoclinas, y optimalidad.

2. Representación matemática rigurosa para estructuras comunes de modelamiento (e.g., balances de flujo, manejo de inventario).

3. Herramientas computacionales: (hoja de cálculo; Solver) y reporte de sensibilidad elemental (rangos permisibles).

Actividad: Casos “Opti-Coffee”: diseño de un plan maestro de producción y distribución para una empresa cafetera, justificando las recomendaciones con análisis de sensibilidad.

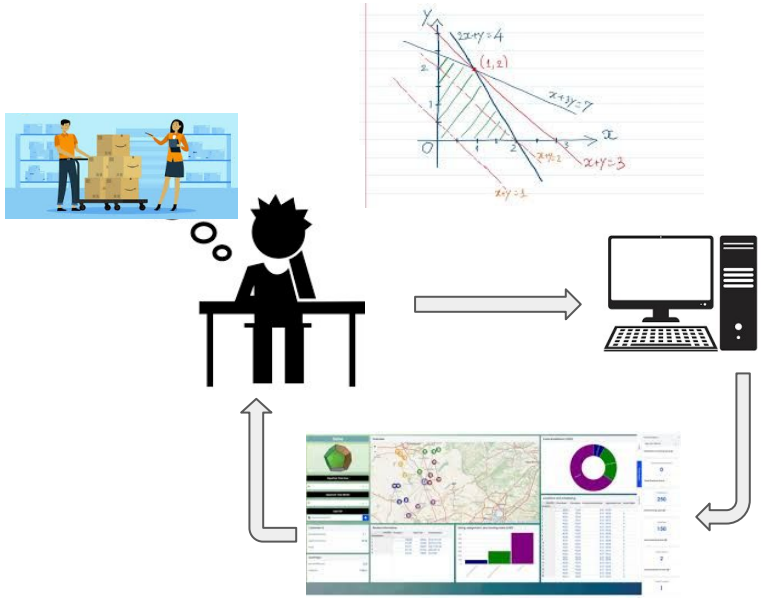

Módulo 2 — Modelos enteros: decisiones discretas/binarias y condiciones lógicas

Propósito: Extender el marco lineal a la programación entera mixta (MIP) para representar decisiones binarias, secuencias y asignaciones.

Contenido:

1. Modelos arquetípicos: *knapsack*, asignación, condiciones lógicas, y scheduling elemental.

2. Formulación de condiciones lógicas (precedencia, consecutividad, etc.) mediante variables binarias.

3. Herramientas computacionales: Python / PuLP y análisis de sensibilidad.

Actividad: Casos“Festivales”: planificación de festivales musicales (asignación, activación, secuenciación).

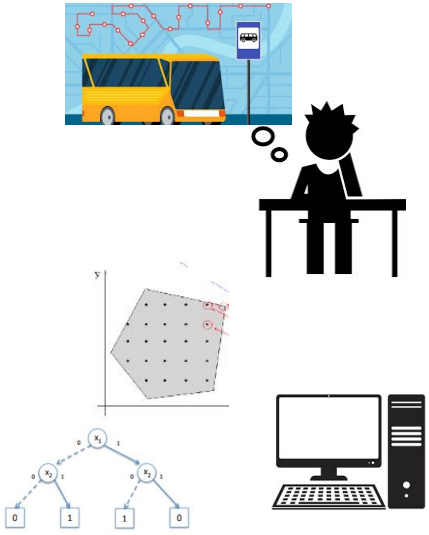

Módulo 3 — Procedimientos de búsqueda para resolver distintos tipos de problemas de optimización

$$\mathbf{x}^{t+1} \longleftarrow \mathbf{x}^{t} + \lambda \Delta \mathbf{x}$$

Propósito: Introducir el principio unificador de la optimización: hallar el mínimo (o máximo) de una función real que cuantifica el desempeño de un sistema.

Contenido:

1. Paradigma de búsqueda iterativa (convergencia, dirección, paso) en el contexto de búsqueda local y heurísticas.

2. Concepto de **función de pérdida** en calibración de modelos paramétricos (‘aprendizaje’). → Sistemas de recomendación, forecasting, clasificación (todos optimizan funciones de pérdida).

3. Descenso por gradiente y métodos heurísticos simples (búsqueda exhaustiva, vecindarios, aleatoria).

Actividad: Implementar métodos de gradiente para calibrar un modelo respecto a datos sintéticos, como base de machine learning supervisado (regresión, SVMs, redes neuronales).

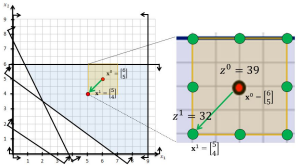

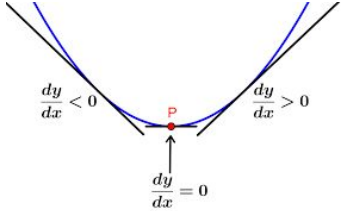

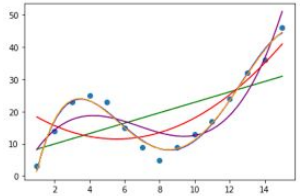

Módulo 4 — Optimización en el tiempo: programación dinámica y heurísticas para decisiones secuenciales

Propósito: Presentar la programación dinámica determinística (DP) como herramienta para decisiones multietapa.

Contenidos:

1. Conceptualización de problemas de decisión en el tiempo (etapas, estados, acciones, transición, recompensa, políticas, valor).

2. Principio de optimalidad de Bellman. Algoritmo de *backwards induction* (horizonte finito): inventario, selección, planeación.

3. Evaluación, simulación e iteración de políticas, para encontrar y comparar decisiones a lo largo del horizonte.

Actividad: Desarrollo de modelos de DP para la gestión de inventario con demanda determinística y comparación con la formulación LP equivalente.

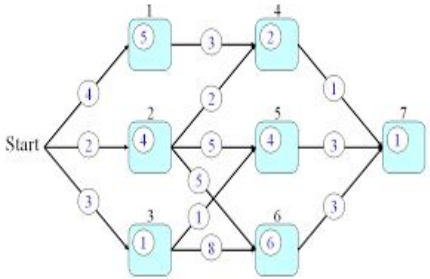

La optimización como motor en diferentes puntos de los sistemas modernos de apoyo a la toma de decisiones

- *Analítica prescriptiva:* Los modelos matemáticos de optimización permiten **representar y solucionar problemas prácticos de decisión** en muchos contextos (transporte, industria, finanzas, salud, …), ofreciendo soluciones implementables y análisis económicos.

- *Analítica predictiva:* Procedimientos computacionales de optimización **soportan diferentes tipos de aprendizaje e inteligencia analítica**, desde modelos de regresión o calificación, hasta el entrenamiento de agentes mediante aprendizaje por refuerzo (como extensión de la programación dinámica).

- En conjunto, los modelos predictivos y prescriptivos ofrecen modelos valuables y consistentes del mundo (simulación, pronósticos, sistemas de control), supliendo la principal limitación de los modelos de IA generativa que, a pesar de su impacto, no son confiables en muchos contextos

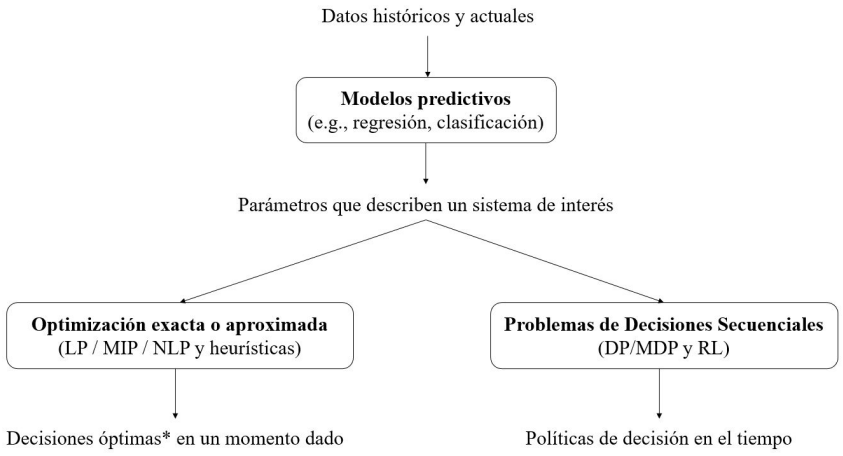

La optimización como motor en diferentes puntos de los sistemas modernos de apoyo a la toma de decisiones

- *Analítica prescriptiva:* Los modelos matemáticos de optimización permiten representar y solucionar problemas prácticos de decisión en muchos contextos (transporte, industria, finanzas, salud, …), ofreciendo soluciones implementables y análisis económicos.

- *Analítica predictiva:* Procedimientos computacionales de optimización soportan diferentes tipos de aprendizaje e inteligencia analítica, desde modelos de regresión o calificación, hasta el entrenamiento de agentes mediante aprendizaje por refuerzo (como extensión de la programación dinámica).

- En conjunto, los modelos predictivos y prescriptivos ofrecen modelos valuables y consistentes del mundo (simulación, pronósticos, sistemas de control), supliendo la principal limitación de los modelos de IA generativa, que a pesar de su impacto, no son confiables en muchos contextos

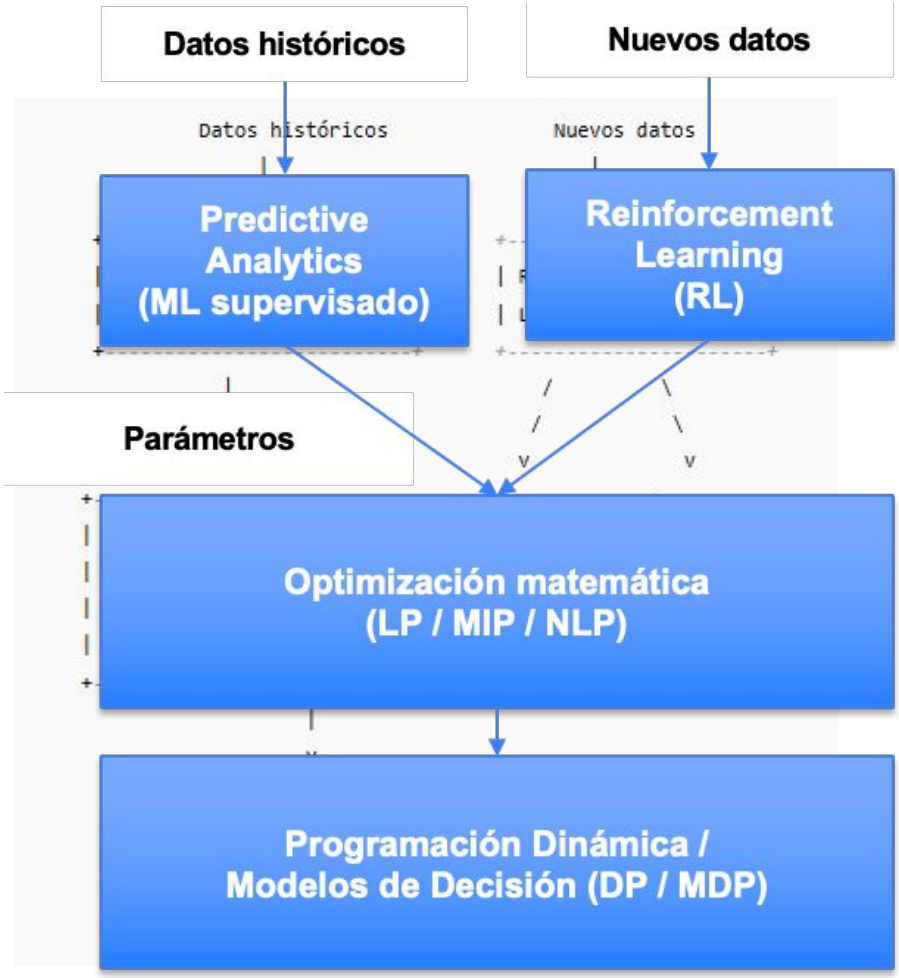

Cursos avanzados en el área de optimización

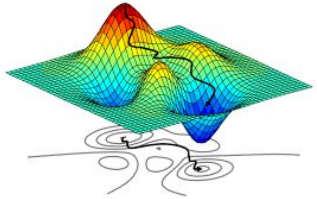

- *Optimización Avanza*
- *Flujo en Redes*
- *Optimización bajo Incertidum*
- *Metaheurísticas*

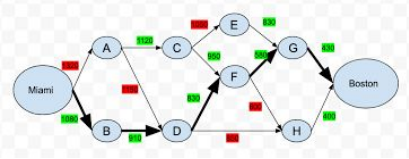

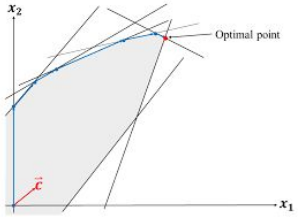

Pre-requisitos:

- Cálculo
- Álgebra lineal
- Programación básica en Python

Al finalizar el curso serás capaz de:

Identificar y clasificar problemas determinísticos de optimización (continuos, LP, MIP, DP).

Formular rigurosamente modelos LP y MIP con notación algebraica estándar.

Implementar en Python métodos de gradiente y heurísticas sencillas, así como programación matemática y algoritmos de DP finita.

Integrar modelos de optimización en flujos de datos reales y comunicar hallazgos a audiencias técnicas y no técnicas.

Trabajar en equipos multidisciplinarios para diseñar soluciones basadas en optimización ética y responsable.

Modelado en Optimización

1. Descripción del curso

Este curso ofrece una introducción al modelamiento, solución y análisis de problemas de optimización como motor de apoyo para la toma de decisiones en diferentes dominios de aplicación. Se busca familiarizar al estudiante con diversos tipos de problemas de ciencias de la decisión y ciencia de datos, integrando la **analítica predictiva y prescriptiva** para implementar soluciones computacionales y comunicar hallazgos a audiencias técnicas y no técnicas.

2. Objetivos generales

Al finalizar el curso, se espera que el estudiante esté en capacidad de:

- **Identificar y clasificar** situaciones susceptibles de ser mejoradas mediante técnicas de optimización, diferenciando problemas de **decisión** y de **estimación**.
- Formular rigurosamente problemas de optimización, representando situaciones reales a través de modelos matemáticos de **programación lineal y entera** (LP y MIP).
- Implementar y resolver modelos mediante *solvers* existentes (e.g., Excel, Python + PuLP) o algoritmos de búsqueda iterativa o programación dinámica.
- Analizar, interpretar y comunicar hallazgos de forma ética, integrando modelos de optimización en flujos de datos reales.