Modelado en Optimización

Departamento de Ingeniería Industrial
Universidad de los Andes

Overview

Este curso ofrece una introducción al ***modelamiento, solución y análisis de problemas de optimización*** como herramienta de apoyo para la **toma de decisiones en diferentes dominios de aplicación**.

Al finalizar el curso, estarás en capacidad de:

- Identificar **situaciones susceptibles de ser mejoradas** a través de la optimización
- Representar **problemas de decisión** mediante modelos de programación lineal
- Implementar y analizar las **soluciones computacionales** correspondientes
- **Comunicar hallazgos y recomendaciones** a una audiencia amplia.

Modelar

Resolver

Analizar

Contenido

A lo largo de cuatro módulos, trabajarás para desarrollar las siguientes competencias:

- Representar **problemas de decisión** como **modelos matemáticos** de *programación lineal* y resolverlos computacionalmente mediante el complemento *Solver* en hojas de cálculo, comprendiendo las nociones de región factible, gradiente y optimalidad.

- Modelar problemas comunes de optimización lineal con variables continuas y enteras, e implementar **rutinas de solución y presentación de resultados** de optimización en Python.

- Diferenciar los **tipos de problemas** y principales **estrategias de solución** que se usan en aplicaciones prácticas de optimización, en **problemas de decisión** (analítica prescriptiva, investigación de operaciones) como en **problemas de estimación** (analítica predictiva, inteligencia artificial).

- Formular y resolver problemas de **decisiones secuenciales** bajo el paradigma de *programación dinámica*, y evaluar el desempeño de estrategias de solución exactas y aproximadas.

Módulo 1 — Optimización lineal con restricciones

Propósito: Desarrollar competencias de formulación y solución de modelos matemáticos de programación lineal (LP) en contextos de industria. → Muchos problemas industriales se aproximan “linealizando” el mundo

Contenido:

1. Geometría de un LP: región factible, gradiente, isoclinas, y optimalidad.

2. Representación matemática rigurosa para estructuras comunes de modelamiento (e.g., balances de flujo, manejo de inventario).

3. Herramientas computacionales: (hoja de cálculo; Solver) y reporte de sensibilidad elemental (rangos permisibles).

Actividad: Casos “Opti-Coffee”: diseño de un plan maestro de producción y distribución para una empresa cafetera, justificando las recomendaciones con análisis de sensibilidad.

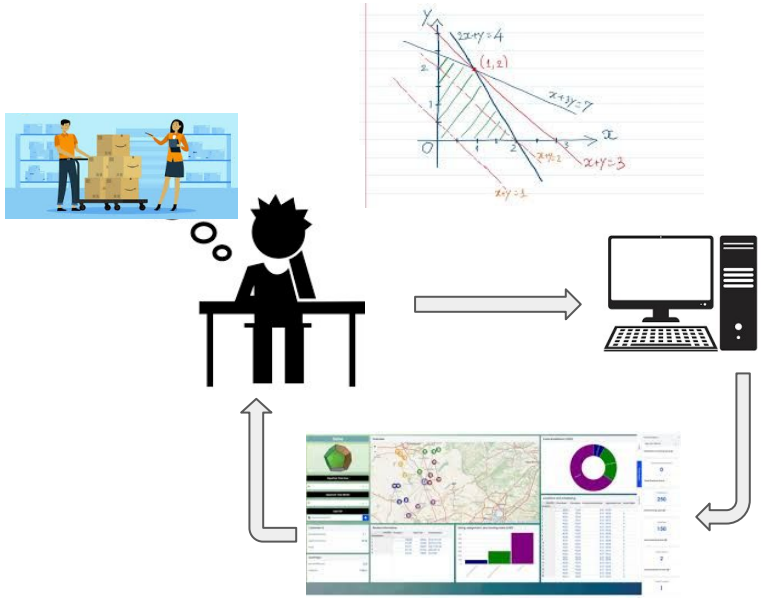

Módulo 2 — Modelos enteros: decisiones discretas/binarias y condiciones lógicas

Propósito: Extender el marco lineal a la programación entera mixta (MIP) para representar decisiones binarias, secuencias y asignaciones.

Contenido:

1. Modelos arquetípicos: *knapsack*, asignación, condiciones lógicas, y scheduling elemental.

2. Formulación de condiciones lógicas (precedencia, consecutividad, etc.) mediante variables binarias.

3. Herramientas computacionales: Python / PuLP y análisis de sensibilidad.

Actividad: Casos“Festivales”: planificación de festivales musicales (asignación, activación, secuenciación).

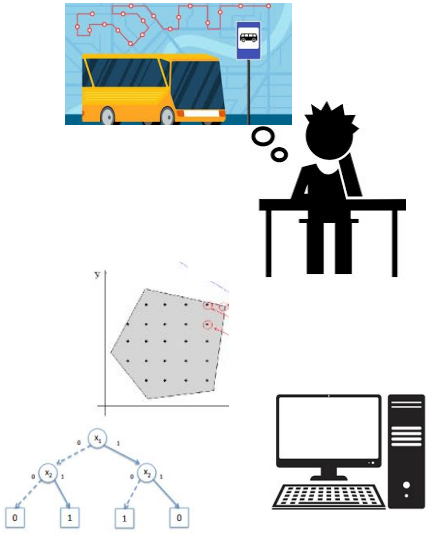

Módulo 3 — Procedimientos de búsqueda para resolver distintos tipos de problemas de optimización

$$\mathbf{x}^{t+1} \longleftarrow \mathbf{x}^{t} + \lambda \Delta \mathbf{x}$$

Propósito: Introducir el principio unificador de la optimización: hallar el mínimo (o máximo) de una función real que cuantifica el desempeño de un sistema.

Contenido:

1. Paradigma de búsqueda iterativa (convergencia, dirección, paso) en el contexto de búsqueda local y heurísticas.

2. Concepto de **función de pérdida** en calibración de modelos paramétricos (‘aprendizaje’). → Sistemas de recomendación, forecasting, clasificación (todos optimizan funciones de pérdida).

3. Descenso por gradiente y métodos heurísticos simples (búsqueda exhaustiva, vecindarios, aleatoria).

Actividad: Implementar métodos de gradiente para calibrar un modelo respecto a datos sintéticos, como base de machine learning supervisado (regresión, SVMs, redes neuronales).

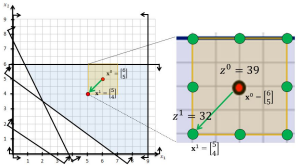

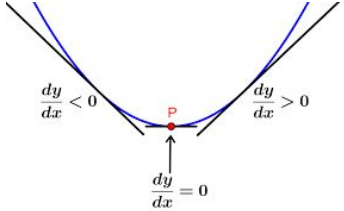

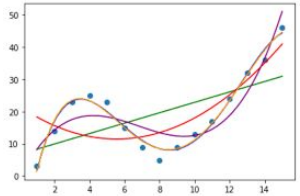

Módulo 4 — Optimización en el tiempo: programación dinámica y heurísticas para decisiones secuenciales

Propósito: Presentar la programación dinámica determinística (DP) como herramienta para decisiones multietapa.

Contenidos:

1. Conceptualización de problemas de decisión en el tiempo (etapas, estados, acciones, transición, recompensa, políticas, valor).

2. Principio de optimalidad de Bellman. Algoritmo de *backwards induction* (horizonte finito): inventario, selección, planeación.

3. Evaluación, simulación e iteración de políticas, para encontrar y comparar decisiones a lo largo del horizonte.

Actividad: Desarrollo de modelos de DP para la gestión de inventario con demanda determinística y comparación con la formulación LP equivalente.

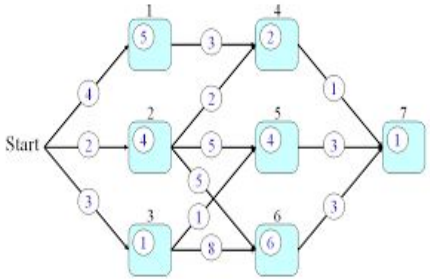

La optimización como motor en diferentes puntos de los sistemas modernos de apoyo a la toma de decisiones

- *Analítica prescriptiva:* Los modelos matemáticos de optimización permiten **representar y solucionar problemas prácticos de decisión** en muchos contextos (transporte, industria, finanzas, salud, …), ofreciendo soluciones implementables y análisis económicos.

- *Analítica predictiva:* Procedimientos computacionales de optimización **soportan diferentes tipos de aprendizaje e inteligencia analítica**, desde modelos de regresión o calificación, hasta el entrenamiento de agentes mediante aprendizaje por refuerzo (como extensión de la programación dinámica).

- En conjunto, los modelos predictivos y prescriptivos ofrecen modelos valuables y consistentes del mundo (simulación, pronósticos, sistemas de control), supliendo la principal limitación de los modelos de IA generativa que, a pesar de su impacto, no son confiables en muchos contextos

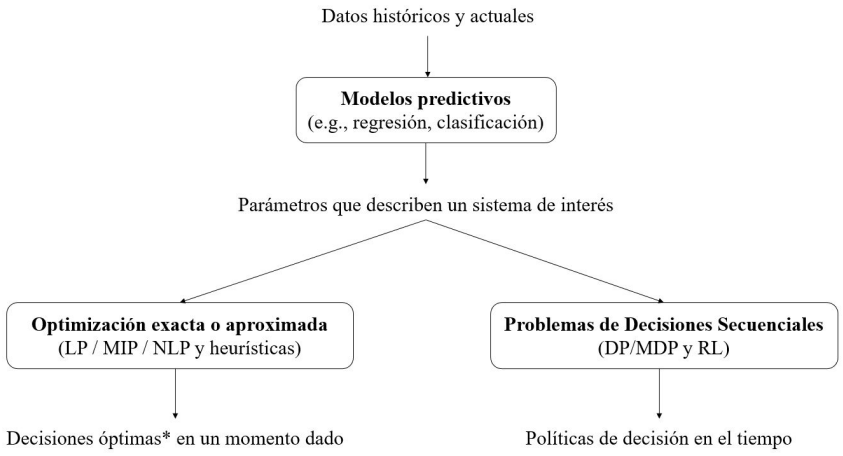

La optimización como motor en diferentes puntos de los sistemas modernos de apoyo a la toma de decisiones

- *Analítica prescriptiva:* Los modelos matemáticos de optimización permiten representar y solucionar problemas prácticos de decisión en muchos contextos (transporte, industria, finanzas, salud, …), ofreciendo soluciones implementables y análisis económicos.

- *Analítica predictiva:* Procedimientos computacionales de optimización soportan diferentes tipos de aprendizaje e inteligencia analítica, desde modelos de regresión o calificación, hasta el entrenamiento de agentes mediante aprendizaje por refuerzo (como extensión de la programación dinámica).

- En conjunto, los modelos predictivos y prescriptivos ofrecen modelos valuables y consistentes del mundo (simulación, pronósticos, sistemas de control), supliendo la principal limitación de los modelos de IA generativa, que a pesar de su impacto, no son confiables en muchos contextos

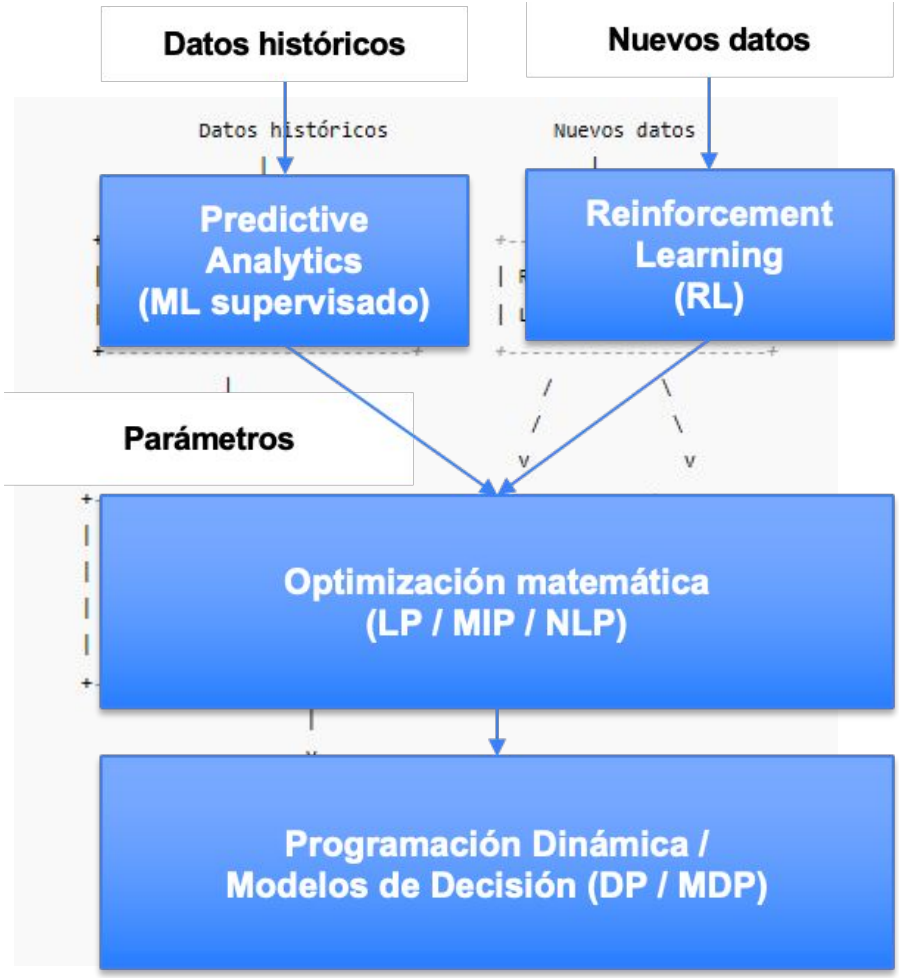

Cursos avanzados en el área de optimización

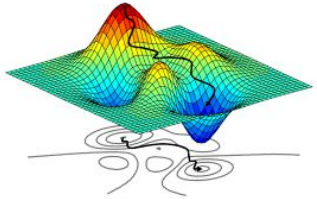

- *Optimización Avanza*
- *Flujo en Redes*
- *Optimización bajo Incertidum*
- *Metaheurísticas*

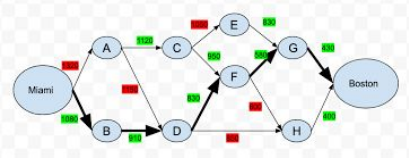

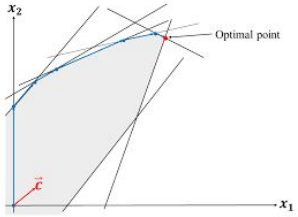

Pre-requisitos:

- Cálculo
- Álgebra lineal
- Programación básica en Python

Al finalizar el curso serás capaz de:

Identificar y clasificar problemas determinísticos de optimización (continuos, LP, MIP, DP).

Formular rigurosamente modelos LP y MIP con notación algebraica estándar.

Implementar en Python métodos de gradiente y heurísticas sencillas, así como programación matemática y algoritmos de DP finita.

Integrar modelos de optimización en flujos de datos reales y comunicar hallazgos a audiencias técnicas y no técnicas.

Trabajar en equipos multidisciplinarios para diseñar soluciones basadas en optimización ética y responsable.